EDA: Panorama Geral

Análise Exploratória de Dados Internações em Saúde Mental / SIH-SUS: SP 2015–2025

Autor	Larissa Yumi Tinem
Data	06.02.2026
Fonte	SIH-SUS

Conteúdo

1. Setup e configuração
2. Carregamento dos dados
3. Qualidade dos dados
4. Volume Geral
5. Cobertura Geográfica
6. Distribuição das Variáveis-Chave
7. Tabela 1 — Características Gerais por Período

Objetivo

Descrever a estrutura e a qualidade do dataset de internações em saúde mental (SIH/SUS (SP), 2015-2025), gerando uma visão consolidada das variáveis principais e a Tabela 1 para publicação.

1. **Setup**

   O notebook utiliza as seguintes bibliotecas Python e configurações de ambiente:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
```

```
from google.colab import drive

# Paleta de Cores
COLOR1 = '#1B4F72' # azul escuro: Pré-Pandemia
COLOR2 = '#48C9B0' # verde-azulado: Pandemia
COLOR3 = '#5499C7' # azul médio: Pós-Pandemia
```

2. **Carregamento dos dados**

   Os dados foram carregados a partir de três arquivos Parquet armazenados no Google Drive,
   correspondentes aos períodos Pré-Pandemia, Pandemia e Pós-Pandemia.
   Após a carga, foi adicionada a coluna periodo e os três DataFrames foram concatenados em um único objeto df.
   Variáveis presentes no dataset: UF_ZI, ANO_CMPT, MES_CMPT, NASC, IDADE, SEXO, RACA_COR,
   ESPEC, IDENT, MUNIC_RES, DIAG_PRINC, DIAG_SECUN, CAR_INT, COBRANCA, MUNIC_MOV,
   CID_ASSO, CID_MORTE, COMPLEX, DT_INTER, DT_SAIDA, QT_DIARIAS, DIAS_PERM, MORTE.

3. **Qualidade dos dados**

   a. **Valores Nulos**

      A verificação de valores nulos em todas as 24 variáveis do dataset retornou zero valores ausentes em qualquer coluna. O dataset está completamente preenchido, sem necessidade de imputação ou remoção de registros

   b. **Valores Duplicados**

      A análise de duplicatas foi realizada em duas etapas. Na primeira, foram detectados 450 registros idênticos (linha a linha). Na segunda etapa, com uma chave de internação composta por 9 campos (UF_ZI, ANO_CMPT, MUNIC_RES, DT_INTER, DT_SAIDA, DIAG_PRINC, SEXO, IDADE, MORTE), foram identificados 17.926 registros duplicados, correspondendo a 1,7% do total de linhas associados a reprocessamentos administrativos. Esses registros foram removidos.

Métrica	Valor
Total de linhas	1.079.670

Duplicatas	450
Duplicatas por chave de internação	17.926 (1,7%)
Total de internações únicas	1.061.744

c. **Consistência das Variáveis Categóricas**

As variáveis categóricas principais foram verificadas quanto a valores inesperados fora do domínio definido. Todas as verificações retornaram resultado positivo.

A consistência temporal também foi verificada: **período coberto de 2015 a 2025**, **sem idades negativas** ou **acima de 120 anos**, sem datas de saída anteriores à internação e sem permanências negativas.

Variável	Valores Esperados	Status
SEXO	['1', '3']	OK
CAR_INT	['01', '02']	OK
MORTE	['0', '1']	OK
COMPLEX	['01', '02', '03']	OK

4. **Volume Geral**

Internações por Período

O período Pré-Pandemia concentrou 51,5% do total de internações da série histórica. Durante a
Pandemia, houve queda acentuada para 22,3% do volume total, evidenciando forte retração no acesso ou na oferta de serviços de saúde mental. No Pós-Pandemia, observa-se recuperação parcial para 26,1%, porém ainda significativamente inferior ao patamar original.

Período	Internações	% do Total
Pré-Pandemia	556.336	51,5%
Pandemia	241.285	22,3%
Pós-Pandemia	282.049	26,1%
Total	**1.079.670**	**100,0%**

Média Mensal de Internações

A média mensal de internações caiu de 9.272 no Pré-Pandemia para 6.702 durante a crise sanitária. O período Pós-Pandemia apresenta recuperação parcial para 7.835, ainda 15,5% abaixo do patamar anterior. Destaca-se a

redução do desvio padrão, sugerindo perda da capacidade de oscilação do sistema.

Período	Média Mensal	Desvio Padrão	Mediana
Pré-Pandemia	9.272	1.338	8.657
Pandemia	6.702	589	6.661
Pós-Pandemia	7.835	359	7.799

Variação Percentual Entre Períodos

A rede de saúde mental em São Paulo sofreu um baque estrutural durante a pandemia. O volume médio de internações despencou 27,7%, chegando a 6.702 atendimentos mensais. Embora o pós-pandemia tenha apresentado melhora (7.835/mês), o sistema ainda opera com déficit de 15,5% em relação ao patamar pré-crise. O ponto mais preocupante é a compressão da variação mensal, indicando um sistema que perdeu capacidade de resposta e flexibilidade.

Comparação	Variação (%)
Pré-Pandemia → Pandemia	-27,7%
Pandemia → Pós-Pandemia	+16,9%
Pré-Pandemia → Pós-Pandemia	-15,5%

5. **Cobertura Geográfica**

A análise geográfica revela forte centralização da oferta hospitalar em um número reduzido de
municípios, com implicações para o acesso regional aos serviços de saúde mental.

Cada município que oferece internação atende, em média, pacientes provenientes de 3,8 municípios diferentes. O percentual de 73,6% de municípios sem serviço próprio de internação psiquiátrica aponta para possível desigualdade regional no acesso e sugere a necessidade de investigar fluxos de evasão para identificar polos sobrecarregados.

Indicador	Valor
Municípios de residência	1.256
Municípios de internação	332
Razão residência / internação	3,8x

Municípios sem serviço de internação	924 (73,6%)

6. **Distribuição das Variáveis-Chave**

   Estatísticas Descritivas: Idade e Tempo de Permanência

   O perfil etário concentra-se em adultos jovens e de meia-idade, com pico na faixa dos 30 aos 50 anos. Em relação ao tempo de permanência, destaca-se o acúmulo massivo de casos com exatamente 30 dias, sugerindo um padrão administrativo ou teto de faturamento do sistema, e não uma distribuição puramente clínica.

Estatística	Idade (Anos)	Dias_Perm (dias)
N	1.079.670	1.079.670
Média	43,0	18,0
Desvio Padrão	15,9	12,1
Mínimo	0	0
Percentil 25	31	6
Mediana	42	18
Percentil 75	54	30
Máximo	99	261

   Taxa de Óbito

   A taxa de óbito hospitalar para internações de saúde mental é historicamente baixa. Durante a pandemia permaneceu praticamente estável, sugerindo que o desfecho de óbito não foi o principal impacto direto da crise nesse setor assistencial.

Período	Taxa de Óbito
Pré-Pandemia	0,29%
Pandemia	0,30%
Pós-Pandemia	0,27%
Geral	0,29%

7. **Tabela 1 - Características Gerais Por Período**

periodo	Pre-Pandemia	Pandemia	Pos-Pandemia	Total
N internações	556336	241285	282049	1079670
Média mensal	9272.0	6702.0	7835.0	8179.0
Idade — média (dp)	44.5 (16.3)	42.2 (15.8)	40.6 (14.9)	43.0 (15.9)
Idade — mediana	44.0	41.0	40.0	42.0
% Feminino	37.6%	38.4%	39.0%	38.1%
% Masculino	62.4%	61.6%	61.0%	61.9%
% Branca	54.1%	53.3%	54.9%	54.1%
% Parda	8.7%	9.1%	9.2%	8.9%
% Preta	21.8%	26.6%	34.9%	26.3%
% Ignorado (raça)	14.9%	10.4%	0.3%	10.1%
Dias perm. — média (dp)	19.8 (12.0)	17.0 (11.9)	15.2 (11.7)	18.0 (12.1)
Dias perm. — mediana	25.0	16.0	13.0	18.0
% Urgência	55.7%	63.3%	63.8%	59.5%
% Óbito	0.29%	0.30%	0.27%	0.29%
% Evasão municipal	38.8%	38.8%	41.1%	39.4%

Considerações Finais

- **Impacto da pandemia:** Queda de 27,7% na média mensal de internações, com recuperação parcial de 16,9% no pós-pandemia, mas déficit persistente de 15,5%.
- **Centralização da assistência:** 73,6% dos municípios que geram pacientes não possuem serviço de internação próprio, indicando forte dependência de deslocamento.
- **Perfil clínico:** Predomínio de adultos (30–50 anos), sexo masculino (61,9%), com tempo mediano de 18 dias de internação e padrão de corte a 30 dias.
- **Etnia/cor:** Tendência de melhora no preenchimento ao longo dos anos; item a documentar como
limitação do artigo.